

$$P \xrightarrow{f_A(P)} a$$

f_A es desconocida

$$f_A: X \rightarrow Y$$

tipicamente $X = \mathbb{R}^n$

$$X = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$$

x es un vector

Si $Y = \mathbb{R}$ Regresión

Si $Y = \{-1, 1\}$ Clasificación binaria

Si $Y = \{C_1, C_2, \dots, C_k\}$ Clasificación en varias clases

$\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\}$ es una muestra de X
 $D = \{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$
 donde $y^{(i)} = f_A(x^{(i)}) + \epsilon$ V.A. i.i.d.

El problema encontrar una función $h^*: X \rightarrow Y$ desconocida
 tal que $h^* \approx f_A$

$h^* \in H$ hipótesis posibles

$H = \{h_\theta | h_\theta: \mathbb{R} \rightarrow \mathbb{R} \text{ donde } h_\theta(x) = \alpha x, \forall \alpha \in \mathbb{R}\}$

$h: X \times \Theta \rightarrow Y, \Theta = \mathbb{R}^p$

$$h(x^{(i)}, \theta) = \hat{y}^{(i)}$$

Si θ es un vector de parámetros físicos

$$h_\theta: X \rightarrow Y$$

$$h_\theta(x) = \sum_{j=1}^J w_j x^j + w_0, x^j \in \mathbb{R}$$


$$h_\theta: \mathbb{R} \rightarrow \mathbb{R}$$

$$\theta = (w_0, w_1, \dots, w_J) \in \mathbb{R}^{J+1}$$

$$\hat{y} = w_0 x + w_1, \hat{y} = w_0 x^2 + w_1 x + b$$

Hipótesis:

1. $f: X \rightarrow Y$ existe y es desconocida
2. Tengo $\{x^{(1)}, \dots, x^{(m)}\} \subseteq X$ una muestra de m datos con distribución desconocida
3. $D = \{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$, donde $y^{(i)} = f(x^{(i)}) + e^{(i)}$ donde $e^{(i)}$ son vector de errores
4. Tenemos una función "Parametrizada" $h: X \times \Theta \rightarrow Y$, típicamente $\Theta = \mathbb{R}^p$
5. Para un valor específico de Θ , $h_\Theta: X \rightarrow Y$
6. $h^* \in \mathcal{H}$ Conjunto de hipótesis
7. El aprendizaje supervisado consiste en encontrar $h^* \in \mathcal{H}$ tal que $h^* \approx f$



$L: Y \times Y \rightarrow \mathbb{R}$ Función de Pérdida

$$L(y, \hat{y}) = L(f(x), h^*(x))$$

$$L(y, \hat{y}) = \frac{1}{2} (y - \hat{y})^2$$

$$= \begin{cases} |y - \hat{y}| & y \in \mathbb{R} \\ |y - \hat{y}| \end{cases}$$

$$L(y, \hat{y}) = \begin{cases} 0 & \text{si } y = \hat{y} \\ 1 & \text{si } y \neq \hat{y} \end{cases} = \mathbb{I}\{y \neq \hat{y}\} \quad y \in \{-1, 1\}$$

↓ Error fuera de muestra

$$E_{out}(h^*) = \sum_{x \in X} [L(f(x), h^*(x))]$$

$$f \approx h^* \text{ si } y \text{ sólo si } E_{out}(h^*) \approx 0$$

$$E_{in} = \frac{1}{m} \sum_{i=1}^m L(y^{(i)}, h(x^{(i)}))$$

$$\uparrow \text{Error en muestra} \quad E_{in}(h^*) \approx 0$$

$$f \approx h^* \text{ si } \swarrow E_{in}(h^*) \approx E_{out}(h^*)$$

Desigualdad de Hoeffding (PAC-Learning)

$$P(|E_{out}(h^*) - E_{in}(h^*)| > \epsilon) \leq 2e^{-2\epsilon^2 m}$$

donde M es el tamaño de la muestra

dimensions

$\text{dvc}(Y) \geq \# \text{ Parámetros INDEPENDIENTES}$

EL APRENDIZAJE ES POSIBLE SI:

$$10^* \text{ dvc}(\mathcal{H}) \leq M \Leftrightarrow E_{\text{in}}(h^+) \cong \Sigma_{\text{out}}(h^+)$$

$$\begin{matrix} X^{(1)T} \\ X^{(2)T} \\ \vdots \\ X^{(m)T} \end{matrix} \rightarrow \begin{matrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{matrix} \quad \begin{matrix} X^{(1)T} \\ X^{(2)T} \\ \vdots \\ X^{(m)T} \end{matrix} \rightarrow \begin{matrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{matrix}$$

$$\Rightarrow D = \{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$$

Conjunto de aprendizaje

$$h_0(x) = w_1x_1 + w_2x_2 + \dots + w_nx_n + b = \sum_{j=1}^n w_j x_j + b = \vec{w}^\top \vec{x} + b$$

$$S: x = (x_1, \dots, x_n) \in \mathbb{R}^n$$

$$w = (w_1, \dots, w_n) \in \mathbb{R}^n$$

$$\theta = (w_1, \dots, w_n, b) \in \mathbb{R}^{n+1}$$

Aprendizaje

$$F_{in}(h^+) \approx F_{out}(h^+)$$

$$\sin(h^*) \approx 0$$

$$h^* = \arg \min E_{\text{in}}(h) \Leftrightarrow \theta^* = w^*, b^* = \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} E_{\text{in}}(h_w, b)$$

$$w^*, b^* = \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{m} \sum_{i=1}^m \frac{1}{2} (y^{(i)} - h_{w,b}(x^{(i)}))^2$$

MSE
Mean Square Error

$$w^*, b^* = \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{M} \sum_{i=1}^M \frac{1}{2} (y^{(i)} - \underbrace{(w^\top x^{(i)}) - b}_{= x^{(i)\top} w - b})^2$$

$$= \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{2M} \left[(y^{(1)} - x^{(1)\top} w - b)^2 + \dots + (y^{(m)} - x^{(m)\top} w - b)^2 \right] \begin{pmatrix} y^{(1)} - x^{(1)\top} w - b \\ y^{(2)} - x^{(2)\top} w - b \\ \vdots \\ y^{(m)} - x^{(m)\top} w - b \end{pmatrix}$$

$$= \arg \min_{\theta \in \mathbb{R}^n} \frac{1}{M} [y - [x_i]^\top \theta]^T [y - [x_i]^\top \theta]$$

Para encontrar un mínimo de una función: se deriva y se iguala a cero

En este caso como tenemos dos variables tenemos que derivar parcialmente. Para encontrar el gradiente.

Ejemplo: $f(x_1, \dots, x_n)$, $x \in \mathbb{R}^n$, $f: \mathbb{R}^n \rightarrow \mathbb{R}$

$$\frac{\partial f(x)}{\partial x_1}$$

$$\frac{\partial f(x)}{\partial x_2}$$

$$\vdots$$

$$\frac{\partial f(x)}{\partial x_n}$$

Regresamos al problema...

$$[y - x_e \theta]^T [y - x_e \theta]$$

$$\sum_{m=1}^M [y - x_e \theta]$$

$$\partial (y - x_e \theta)^2 = -2(y - x_e \theta) x_e$$

$$\frac{1}{M} x_e^T [y - x_e \theta] = \vec{0}$$

$$x_e^T y - x_e^T x_e \theta = \vec{0}$$

$$x_e^T x_e \theta = x_e^T y$$

$$\theta = \underbrace{[x_e^T x_e]^{-1} x_e^T y}_{\text{Pinv}(x_e)} \leftarrow \text{Este es el método mínimo de cuadrados}$$